ACTIVIDAD DE APRENDIZAJE 1

Entendimiento y Exploración de Datos

North Quay Gifts | Online Retail II

Fase CRISP-DM Data Understanding

Equipo o participante	Fecha de entrega
[Completar]	[Completar]

Propósito

Describe la estructura, las distribuciones y la calidad del historial transaccional de North Quay Gifts. Sustenta tu diagnóstico con tablas y visualizaciones y termina con un plan de acción para la preparación de los datos.

Recursos necesarios

Utiliza el caso empresarial, el archivo original online_retail_II.csv y una libreta de Python con Pandas y una biblioteca de visualización. La libreta NB2 Exploración de Datos sirve como referencia; amplía su diagnóstico con las investigaciones de esta actividad.

Datos originales: https://drive.google.com/file/d/1VXcIp-m6PazATaH-4JiYQDACYfCpSSqm/view

Libreta de referencia: https://drive.google.com/file/d/1ofrB0Wx9JZvBW0GWVafDEzw--qvUqdrT/view

Instrucciones de trabajo

Completa este documento como Reporte de Análisis Exploratorio de Datos. Sustituye los campos entre corchetes, incorpora las figuras y responde las preguntas con cifras o ejemplos verificables. Los espacios son editables y pueden ampliarse. Conserva los nombres de las secciones para relacionar el reporte con la libreta.

Trabaja sobre el conjunto completo. Distingue los conteos de líneas, facturas y clientes. Cuando calcules porcentajes, indica el denominador; redondea solo la presentación de resultados.

Puedes interpretar InvoiceDate como fecha en una copia de trabajo para reconocer su cobertura. Conserva el archivo y los valores originales. Documenta las fechas que no puedan interpretarse, si las encuentras.

Alcance

Esta actividad termina con un diagnóstico y un plan de acción. No elimines, imputes, concilies ni corrijas transacciones. No construyas LineAmount u otras variables derivadas, indicadores de ventas o agregaciones por fecha. Las máscaras temporales para inspeccionar casos no deben sustituir el conjunto original.

No se solicitan correlaciones ni diagramas de dispersión. En las visualizaciones categóricas cuenta líneas del archivo; una frecuencia alta no demuestra mayores ingresos.

Entregables

1. Este reporte completo en un documento editable, como instrumento principal de evaluación.
2. Libreta .ipynb ejecutada, con los cálculos, las visualizaciones y las celdas identificadas por sección. La libreta respalda el reporte; sus salidas deben coincidir.

1 Reconocimiento de los datos

Examina las dimensiones, las columnas y sus tipos. Identifica el periodo con fechas interpretadas, no mediante el orden alfabético de textos. Completa las tablas sin modificar los registros.

Indicador	Resultado
Número de líneas y columnas	[Completar]
Primera y última fecha con hora	[Completar]
Facturas distintas y clientes identificados distintos	[Completar]
Unidad representada por una fila	[Completar]

Clasifica las variables por su función analítica. Un identificador puede ser una categoría nominal aunque se almacene como número. Los clientes faltantes no cuentan como un cliente adicional.

Columna	Tipo en Pandas	Función y significado
Invoice	[Completar]	[Completar]
StockCode	[Completar]	[Completar]
Description	[Completar]	[Completar]
Quantity	[Completar]	[Completar]
InvoiceDate	[Completar]	[Completar]
Price	[Completar]	[Completar]
Customer ID	[Completar]	[Completar]
Country	[Completar]	[Completar]

1. Selecciona una factura con varios productos. Reporta su identificador, número de líneas y número de StockCode distintos. ¿Por qué esos conteos pueden diferir? ¿Por qué el total de filas no equivale al número de pedidos?

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

2. Explica por qué el promedio de Customer ID o de un código de producto no describe el comportamiento de compra. ¿Qué diferencia existe entre el tipo de almacenamiento y el significado de una columna?

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

3. ¿El primer y el último mes están completos? Explica qué restricción introduce la cobertura observada al comparar periodos.

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

2 Estadística descriptiva

Resume Quantity y Price sobre el conjunto original. Excluye los identificadores de las medidas numéricas. Reporta valores no nulos, media, mediana, desviación estándar, cuartiles, extremos, asimetría y curtosis; para esta última, indica la convención utilizada. Puedes apoyarte en describe(), skew() y kurt().

Estadístico	Quantity en unidades	Price en GBP por unidad
Observaciones no nulas	[Completar]	[Completar]
Media	[Completar]	[Completar]
Mediana	[Completar]	[Completar]
Desviación estándar	[Completar]	[Completar]
Mínimo	[Completar]	[Completar]
Primer cuartil	[Completar]	[Completar]
Tercer cuartil	[Completar]	[Completar]
Máximo	[Completar]	[Completar]
Asimetría	[Completar]	[Completar]
Curtosis	[Completar]	[Completar]

Resume Country y StockCode como categorías: valores presentes, categorías distintas, categoría más frecuente y su frecuencia. Registra por separado los nulos, sin convertirlos en una categoría real.

Variable	Presentes	Distintos	Categoría más frecuente y líneas
Country	[Completar]	[Completar]	[Completar]
StockCode	[Completar]	[Completar]	[Completar]

4. Compara media y mediana de cada medida. Relaciona las diferencias con la asimetría y con los extremos observados; evita afirmar que una media representa una compra típica sin justificarlo.

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

5. ¿Qué sugieren los mínimos y máximos de Quantity y Price? Distingue lo que muestran los datos de una explicación que necesitaría confirmación empresarial.

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

6. ¿Dónde observas mayor dispersión? Sustenta tu respuesta con cuartiles y desviación estándar dentro de cada variable. Quantity y Price tienen unidades distintas: no compares sus desviaciones como si midieran lo mismo. ¿Cómo pueden los extremos afectar sus promedios?

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

3 Análisis univariado

Genera las visualizaciones sobre Quantity y Price originales. Conserva una vista del rango completo. Si los extremos impiden leer la concentración central, añade una vista ampliada e indica los límites y la proporción de observaciones que queda fuera de esa vista. El ajuste visual no autoriza a eliminar registros.

Figuras 1 y 2 Histogramas de Quantity y Price
[Inserta la figura con título, ejes y unidad de medida legibles.]

7. Describe dónde se concentra cada distribución, su asimetría y la presencia de valores negativos o extremos. Cita al menos un estadístico que respalde la lectura de cada histograma.

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

Construye diagramas de barras para Country y StockCode con las diez categorías más frecuentes. Las barras deben representar número de líneas. Indica el total de categorías de cada variable y el porcentaje de líneas cubierto por las diez mostradas; no presentes ese subconjunto como si fuera el total.

Figuras 3 y 4 Frecuencias de Country y StockCode
[Inserta la figura con título, ejes y unidad de medida legibles.]

Explora unique(), nunique() y value_counts() para esas dos variables. Registra las tres categorías más frecuentes con su cantidad de líneas y porcentaje sobre el total de líneas del archivo.

Variable	Categorías distintas	Tres categorías con líneas y porcentaje
Country	[Completar]	[Completar]
StockCode	[Completar]	[Completar]

8. ¿Qué concentración o diversidad muestran las frecuencias? ¿Por qué el país o producto con más líneas no necesariamente tiene más pedidos, unidades o ingresos?

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

Figuras 5 y 6 Boxplots de Quantity y Price
[Inserta la figura con título, ejes y unidad de medida legibles.]

9. Interpreta mediana, rango intercuartílico y puntos fuera de los bigotes. Indica la regla usada por tu gráfico. Explica por qué un punto atípico no basta para declarar un registro erróneo y relaciona tus conclusiones con los histogramas.

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

4 Diagnóstico de calidad de datos

Calcula los valores nulos y su porcentaje sobre todas las líneas, incluidos los registros repetidos. Conserva el mismo denominador para las ocho columnas.

Columna	Nulos	Porcentaje sobre el total
Invoice	[Completar]	[Completar]
StockCode	[Completar]	[Completar]
Description	[Completar]	[Completar]
Quantity	[Completar]	[Completar]
InvoiceDate	[Completar]	[Completar]
Price	[Completar]	[Completar]
Customer ID	[Completar]	[Completar]
Country	[Completar]	[Completar]

Cuenta las copias exactas adicionales a la primera ocurrencia con duplicated(). Considera las ocho columnas originales. Inspecciona ejemplos completos antes de proponer un tratamiento; una repetición no confirma por sí sola un error de captura.

Situación	Líneas	Porcentaje sobre el total
Duplicados exactos adicionales	[Completar]	[Completar]
Quantity < 0	[Completar]	[Completar]
Quantity = 0	[Completar]	[Completar]
Price < 0	[Completar]	[Completar]
Price = 0	[Completar]	[Completar]

10. ¿Qué análisis de clientes se limitan por la falta de Customer ID? ¿Por qué esas mismas líneas todavía podrían ser útiles para estudiar actividad comercial global?

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

11. Examina al menos dos ejemplos de duplicados o de precios no positivos. Registra Invoice, StockCode, Quantity, Price y Description en la libreta. ¿Qué evidencia permite describirlos y qué información faltaría para decidir si deben excluirse?

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

Documenta otros problemas que encuentres, por ejemplo descripciones faltantes, códigos administrativos o fechas que no puedan interpretarse. Si no hay casos de una condición solicitada, informa cero; no omitas la comprobación.

Otros hallazgos con evidencia: [Completa con evidencia de tu libreta.]

5 Investigación de cancelaciones y cantidades negativas

A Facturas con prefijo C

Identifica Invoice como texto y revisa el prefijo C sin confundirlo con letras presentes en otras posiciones. Puedes utilizar str.startswith(). Sobre las líneas identificadas, cuenta facturas distintas y examina el signo de Quantity. No cambies sus cantidades.

Indicador	Resultado
Líneas con prefijo C	[Completar]
Facturas C distintas	[Completar]
Líneas C con Quantity < 0	[Completar]
Líneas C con Quantity = 0	[Completar]
Líneas C con Quantity > 0	[Completar]

B Cantidades negativas sin prefijo C

Selecciona Quantity < 0 y facturas que no comienzan con C. Cuenta líneas y facturas distintas. En la libreta, inspecciona al menos cinco casos con Invoice, StockCode, Description, Quantity, Price, Customer ID e InvoiceDate; revisa qué precios y datos de cliente presentan.

Líneas negativas sin C	Facturas distintas	Hallazgos en precios y clientes
[Completar]	[Completar]	[Completar]

12. ¿Qué explicaciones son compatibles con las descripciones observadas, como ajustes, daños o devoluciones? Distingue esas hipótesis de una causa confirmada. ¿Se puede interpretar cualquier negativo como una devolución de venta?

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

C Comparación de conjuntos

Cruza el prefijo de Invoice con el signo de Quantity sobre todas las líneas originales. Incluye las tres categorías de cantidad aunque alguna tenga cero casos. La suma de las seis celdas debe coincidir con el número de líneas del archivo.

Prefijo de Invoice	Quantity < 0	Quantity = 0	Quantity > 0
Con C	[Completar]	[Completar]	[Completar]
Sin C	[Completar]	[Completar]	[Completar]

13. ¿Coinciden exactamente las líneas C con las cantidades negativas? Sustenta la respuesta con las celdas de la tabla. Si encuentras líneas C con cantidad positiva o cero, inspecciónalas en la libreta y explica por qué requieren revisión específica.

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

6 Plan de acción y evaluación

Propón tratamientos para los hallazgos de las secciones 4 y 5. Incluye los nulos relevantes, los duplicados, los precios no positivos y la relación entre cancelaciones y cantidades negativas. Añade filas cuando dos problemas requieran decisiones diferentes.

En Evidencia, incluye el conteo y un ejemplo verificable e indica si el problema está confirmado o requiere información adicional. En Tratamiento propuesto, justifica la acción y señala qué información solicitarías antes de ejecutarla. En esta actividad ninguna propuesta se implementa.

Problema identificado	Evidencia	Posible impacto empresarial	Tratamiento propuesto
[Completar]	[Completar]	[Completar]	[Completar]
[Completar]	[Completar]	[Completar]	[Completar]
[Completar]	[Completar]	[Completar]	[Completar]
[Completar]	[Completar]	[Completar]	[Completar]
[Completar]	[Completar]	[Completar]	[Completar]

14. ¿Qué decisión de preparación atenderías primero y por qué? Responde en 100 a 150 palabras, con referencia a los conteos y casos del reporte. Explica qué riesgo persistiría aun después del tratamiento propuesto.

Prioridad y justificación: [Completa con evidencia de tu libreta.]

Referencias

Chen, D. (2012). Online Retail II [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5CG6D

Caso de Estudio North Quay Gifts. Material proporcionado. https://docs.google.com/document/d/1luKfmlQgW3RHrsZAIXC30ydZrni3wRQvnw8s3VlLRss/edit