ACTIVIDAD DE APRENDIZAJE 2

Preparación y Procesamiento de Datos

North Quay Gifts | Online Retail II

Fase CRISP-DM Data Preparation

Equipo o participante	Fecha de entrega
[Completar]	[Completar]

Propósito

Implementa dos estrategias de procesamiento y compara sus efectos sobre pedidos, unidades e ingresos diarios. Selecciona una versión transaccional documentada para continuar con la construcción de conjuntos analíticos.

Recursos y punto de partida

Recupera online_retail_II.csv, el caso North Quay Gifts y tu diagnóstico de la Actividad 1. Utiliza Pandas y una biblioteca de visualización. No partas de un archivo ya filtrado que impida reconstruir los registros excluidos.

I Preparación inicial

1. Conserva una copia original y asigna a cada línea un SourceRow estable antes de filtrar. Esta clave sirve para rastrear decisiones; no debe intervenir al buscar duplicados exactos en las ocho columnas originales.

2. Revisa Invoice, StockCode y Customer ID como identificadores e InvoiceDate como fecha y hora. Si normalizas Customer ID como CustomerID, documenta la equivalencia. Conserva los clientes faltantes como nulos, sin inventar una clave compartida. Mantén los precios originales para calcular y comparar; redondea solo los resultados presentados.

3. Decide qué hacer con los duplicados exactos. Justifica la decisión con tu diagnóstico y aplícala igual en ambas rutas. Conserva el conteo de copias adicionales y de líneas retenidas. Documenta por separado otras exclusiones comunes, como fechas no interpretables o medidas no numéricas.

4. Conserva las líneas sin cliente cuando sus campos transaccionales sean utilizables para el resumen global. No imputes clientes ni descripciones para resolver cancelaciones. Separa las excepciones y registra el motivo de cada exclusión. Usa reglas comunes antes de comparar las rutas.

Control inicial	Resultado o decisión
Archivo y periodo original	[Completar]
Líneas originales y duplicados adicionales	[Completar]
Decisión sobre duplicados y fundamento	[Completar]
Otras exclusiones comunes y sus cantidades	[Completar]
Líneas de la base común después de esas decisiones	[Completar]

Completa este documento como informe comparativo. Sustituye los campos y añade tus tablas y figuras. La libreta debe conservar ambas rutas y permitir reconstruir el informe desde el original.

II Estrategias de procesamiento

Ruta A Exclusión de registros

Desde la base común, excluye las facturas cuyo Invoice comienza con C, las líneas con Quantity ≤ 0 y las líneas con Price ≤ 0. Comprueba que todas las conservadas tienen cantidad y precio positivos y carecen del prefijo C. Informa los conteos por condición y también el total excluido sin duplicar líneas que cumplan varias condiciones.

Las líneas conservadas se considerarán compras válidas para este ejercicio. Los importes de A representan ventas brutas de las compras retenidas, antes de reconocer los abonos de B; no representan utilidad ni un estado financiero auditado.

Ruta B Reconocimiento de abonos y conciliación

Conserva las mismas compras válidas de A y añade las líneas con prefijo C, Quantity < 0 y Price > 0 de la base común. Conserva su signo y su fecha de registro. Trátalas como abonos documentados, aunque no logres identificar una factura de origen. Su vínculo con una compra se investiga por separado, como se indica en la página siguiente.

Separa las líneas C con cantidad positiva o cero y los precios no positivos como excepciones. Investiga los negativos sin C mediante sus precios, descripciones y datos de cliente. En la comparación principal, mantenlos fuera del resultado comercial mientras no exista evidencia suficiente para clasificarlos como una devolución de venta. Cuantifica el conjunto y justifica su tratamiento; no lo conviertas automáticamente en ventas positivas.

Esta convención permite comparar compras retenidas frente a compras menos abonos registrados. La conciliación describe la trazabilidad del abono; no determina por sí sola si se reconoce. Informa que una parte de las ventas netas puede incluir abonos sin compra de origen identificada.

Calcula B en la fecha del movimiento: conserva la compra positiva y el abono negativo una vez cada uno. No reduzcas además la compra original ni desplaces el abono a otra fecha. Si exploras una corrección retrospectiva, preséntala como análisis adicional, sin mezclarla con la serie principal.

Control de la ruta	**A**	**B**
Líneas conservadas	[Completar]	[Completar]
Líneas excluidas de la base común	[Completar]	[Completar]
Compras válidas conservadas	[Completar]	[Completar]
Abonos C negativos reconocidos	[Completar]	[Completar]
Excepciones C y negativos sin C	[Completar]	[Completar]

Verifica en cada ruta: líneas conservadas + excluidas = líneas de la base común. En el control de excepciones evita sumar categorías superpuestas como si fueran conjuntos disjuntos. Indica las prioridades usadas para asignar un motivo principal.

Investigación de correspondencias de los abonos

Desarrolla una conciliación conservadora con los abonos C negativos de B. No se exige resolverlos todos. La evaluación se centra en que las reglas sean reproducibles, los vínculos tengan evidencia y las limitaciones estén cuantificadas.

1. Busca compras anteriores con el mismo cliente identificado, StockCode y precio unitario. Compara el precio registrado; si aplicas una tolerancia, justifícala. La compra debe preceder al abono por fecha y hora. Quitar la C de Invoice no constituye una llave de enlace. El archivo no incluye una referencia explícita a la venta cancelada: cada vínculo aceptado es una propuesta analítica según tus reglas.

2. Para evaluar cantidades, agrupa primero las líneas de cada factura de compra por cliente, producto y precio. Conserva la factura y su fecha. Evita un cruce directo de detalle contra detalle que multiplique registros. Si la factura tiene varias horas, exige que la compra candidata esté completa antes del abono.

3. Considera candidata una factura anterior con unidades disponibles suficientes para cubrir el valor absoluto de la cantidad devuelta. Una devolución puede ser parcial. Revisa los abonos en orden cronológico y, cuando aceptes un vínculo, descuenta esas unidades de la capacidad disponible para otros vínculos; no reutilices las mismas unidades.

4. Acepta una correspondencia cuando una sola candidata cumpla las reglas y no haya movimientos pendientes que comprometan ese saldo. Clasifica como ambigua una devolución con varias candidatas o cuya asignación dependa de resolver abonos anteriores. No elijas una factura por cercanía temporal sin justificar esa regla. En esta actividad puedes dejar esos casos pendientes.

5. Clasifica como no conciliados los casos sin cliente o sin candidata suficiente. Una devolución distribuida entre varias facturas, una venta anterior al inicio del archivo o un precio diferente pueden impedir el vínculo. Registra el motivo; no fuerces una conciliación entre varios pedidos ni inventes transacciones.

6. Conserva una tabla de auditoría en la libreta o en un CSV complementario con SourceRow del abono, Invoice C, cliente, producto, precio, fecha, unidades, número de candidatas, factura vinculada si procede, estado y motivo. Reporta líneas y facturas C distintas por estado. Una factura puede tener líneas en estados distintos; sus conteos por estado no necesariamente se suman.

Estado de las líneas	Líneas	Facturas C distintas	Unidades devueltas
Conciliadas según la regla	[Completar]	[Completar]	[Completar]
Ambiguas	[Completar]	[Completar]	[Completar]
No conciliadas	[Completar]	[Completar]	[Completar]

Incorpora en la libreta un caso de cada estado encontrado y una devolución parcial si la identificas. Informa cero cuando un estado no aparezca. Comprueba que la suma de líneas por estado coincide con todos los abonos examinados.

Regla aplicada y limitaciones de la conciliación: [Completa con evidencia de tu libreta.]

III Construcción de indicadores diarios

Calcula LineAmount = Quantity × Price en cada ruta. Deriva Date a partir de InvoiceDate sin la hora y agrupa por día. Los importes están expresados en libras esterlinas, GBP. Conserva una fila por fecha y ruta con las siguientes definiciones.

Campo	Ruta A	Ruta B
Date	Fecha del movimiento	Fecha del movimiento
TotalOrders	Facturas distintas de compra válida	Las mismas facturas de compra válida; las C no son pedidos nuevos
TotalUnits	Suma de Quantity positiva	Suma con signo de compras y abonos
Revenue	Suma de LineAmount de compras	Suma con signo de LineAmount de compras y abonos

Mantén definiciones comparables: TotalOrders cuenta facturas de compra, no líneas ni documentos de abono. Con estas reglas, A y B deben tener el mismo número de pedidos; una diferencia exige revisar el conteo. TotalUnits es bruto positivo en A y neto en B; Revenue representa ventas brutas retenidas en A y ventas netas de abonos registrados en B.

Alinea las dos tablas con la unión de fechas observadas en la base común, ordenadas cronológicamente. Si una fecha tiene movimientos en la base común y ninguno elegible en una ruta, su agregado en esa ruta será cero. Conserva también los días con abonos y sin compras, que pueden tener unidades e ingresos netos negativos.

No agregues automáticamente todos los días del calendario ni inventes ceros para fechas sin ningún registro original. Esas fechas pueden corresponder a cierres o ausencia de información. El archivo representa días con movimientos observados. Identifica las fechas inicial y final y advierte si el primer o último mes es parcial.

Comprueba que las sumas diarias de TotalUnits y Revenue reproducen los totales transaccionales de cada ruta. Los pedidos se cuentan con nunique() dentro de cada día; revisa si una misma factura aparece en fechas diferentes antes de comparar la suma diaria con un conteo global.

Comprobación	A	B
Primera y última fecha	[Completar]	[Completar]
Filas y fechas distintas de la tabla diaria	[Completar]	[Completar]
Total de unidades diario frente al transaccional	[Completar]	[Completar]
Total monetario diario frente al transaccional	[Completar]	[Completar]
Facturas presentes en más de una fecha	[Completar]	[Completar]

Muestra en la libreta las primeras y últimas cinco filas de cada tabla. Exporta indicadores_diarios_comparacion.csv con Route, Date, TotalOrders, TotalUnits y Revenue para ambas rutas. Guarda la ruta elegida en indicadores_diarios.csv sin la columna Route, con Date en formato AAAA-MM-DD. La ingeniería de variables para regresión se realizará después.

IV Comparación del impacto empresarial

Superpone A y B en una gráfica de unidades diarias y otra de ingresos diarios. Mantén las mismas fechas y escalas dentro de cada comparación. Añade una tabla o gráfica de diferencias por día. Si agregas por mes para facilitar la lectura, conserva las series diarias y advierte sobre los meses parciales.

Figura 1 Evolución diaria de unidades de A y B
[Inserta la figura con título, ejes y unidad de medida legibles.]

Figura 2 Evolución diaria de ingresos de A y B
[Inserta la figura con título, ejes y unidad de medida legibles.]

Figura 3 o tabla Diferencias diarias de unidades e ingresos
[Inserta la figura con título, ejes y unidad de medida legibles.]

Para pedidos, unidades e ingresos calcula Δ = B − A y Δ % = 100 × (B − A) / A. Conserva el signo; cuando A sea cero, informa No calculable en el porcentaje y reporta la diferencia absoluta. Para todo el periodo, calcula el porcentaje con los totales, sin promediar porcentajes diarios.

Indicador acumulado	**A**	**B**	**Δ B menos A**	**Δ % sobre A**
Pedidos diarios sumados	[Completar]	[Completar]	[Completar]	[Completar]
Unidades	[Completar]	[Completar]	[Completar]	[Completar]
Ingresos en GBP	[Completar]	[Completar]	[Completar]	[Completar]

Identifica los tres días con mayor magnitud de diferencia monetaria absoluta y revisa los abonos que la explican. Completa una fila por día. Puedes añadir un resumen mensual para contextualizarlos.

Fecha	**Δ ingresos GBP**	**Δ % sobre A**	**Movimientos que explican la diferencia**
[Completar]	[Completar]	[Completar]	[Completar]
[Completar]	[Completar]	[Completar]	[Completar]
[Completar]	[Completar]	[Completar]	[Completar]

1. ¿Cuál es la diferencia acumulada de ingresos y de unidades? ¿Qué abonos explican los días con mayor diferencia? Comprueba que B − A coincide con la suma de los abonos reconocidos, dado que las compras y exclusiones comunes son las mismas.

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

2. ¿Cómo cambia la lectura del desempeño comercial al reconocer devoluciones? Sustenta la respuesta con dos periodos observados. Distingue un cambio en compras de un cambio provocado por abonos.

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

Evaluación de estrategias y decisión final

Aspecto	Ruta A	Ruta B
Reglas aplicadas y referencia al control de líneas	[Completar]	[Completar]
Tratamiento de cancelaciones y otros negativos	[Completar]	[Completar]
Qué representa el indicador de ingresos	[Completar]	[Completar]
Riesgos y limitaciones para informar a dirección	[Completar]	[Completar]

3. ¿Qué ruta recomiendas para informar a la dirección y para continuar el análisis? Fundamenta la elección con los resultados, el alcance del indicador y la proporción de abonos sin vínculo confiable. Explica qué limitaciones persisten. No llames utilidad a Revenue; no se dispone de costos.

Recomendación final y ruta seleccionada: [Completa con evidencia de tu libreta.]

Entregables

1. Libreta .ipynb ejecutada con ambas rutas, auditoría y comparaciones.
2. Este informe completo, con tablas, gráficas y decisión final.
3. transacciones_procesadas.csv de la ruta elegida, con columnas originales, SourceRow, LineAmount, Date y MovementType (Purchase o Credit). Documenta decisiones y campos añadidos; conserva las exclusiones y sus motivos en la libreta.
4. indicadores_diarios.csv de la ruta elegida e indicadores_diarios_comparacion.csv con ambas rutas. Identifica cualquier auditoría exportada como complemento.

Exporta los CSV sin índice adicional y conserva los nulos. Mantén compras y abonos en sus fechas originales; los movimientos posteriores no deben reescribir el historial.

Referencias

Chen, D. (2012). Online Retail II [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5CG6D

Caso de Estudio North Quay Gifts. Material proporcionado. https://docs.google.com/document/d/1luKfmlQgW3RHrsZAIXC30ydZrni3wRQvnw8s3VlLRss/edit