ACTIVIDAD DE APRENDIZAJE 3

Construcción de Conjuntos Analíticos

North Quay Gifts | Online Retail II

Fase CRISP-DM Data Preparation

Equipo o participante	Fecha de entrega
[Completar]	[Completar]

Propósito

Transforma la versión transaccional elegida en la Actividad 2 en dos tablas con una fila por cliente: un conjunto RFM para segmentación posterior y otro para estudiar recompra en los 90 días siguientes a un corte.

Recursos y reglas compartidas

Utiliza transacciones_procesadas.csv, su documentación de decisiones, el caso North Quay Gifts y Pandas. No repitas la limpieza. Registra la ruta A o B seleccionada y verifica que el archivo conserva fechas originales, identificadores y tipo de movimiento. La serie diaria de la Actividad 2 se reserva para regresión posterior.

Una compra válida es una línea sin prefijo C, con Quantity > 0 y Price > 0 que fue conservada en la Actividad 2. Un pedido válido es una factura distinta con al menos una de esas líneas. Las cancelaciones, devoluciones y ajustes no son por sí mismos nuevas compras. La política mantiene la compra registrada y, en B, reconoce el abono por separado en su fecha; no reescribe retrospectivamente esa compra.

Para los análisis por cliente, utiliza solo Customer ID presentes y renombra esa columna como CustomerID en los archivos de salida. Conserva una representación consistente, sin convertir los nulos en clientes ficticios. Cuantifica las líneas y el importe excluidos por falta de identificador. No elimines esas líneas de los archivos globales de la actividad anterior.

Recency y Frequency se calculan solo con compras válidas. Monetary y TotalSpent siguen la ruta seleccionada: en A, suma de compras; en B, compras más abonos con su signo dentro del periodo correspondiente y para los clientes incluidos. Describe el importe de B como neto de abonos registrados. Excluye del conteo de compras los movimientos Credit.

No uses vínculos de conciliación encontrados después de un corte para modificar retrospectivamente las compras o el gasto anterior. Filtra primero el periodo y después agrega; un abono solo interviene si ya estaba registrado dentro de ese periodo.

Control de origen	Registro
Archivo, ruta seleccionada y versión o fecha	[Completar]
Líneas de compras y abonos disponibles	[Completar]
Líneas e importe excluidos por falta de cliente	[Completar]
Definición monetaria aplicada	[Completar]

I Construcción de RFM para clustering

Utiliza todo el periodo transaccional procesado, hasta el 9 de diciembre de 2011 inclusive. Fija la fecha de referencia en el 10 de diciembre de 2011 a las 00:00, día siguiente al último día cubierto por el archivo original. Mantén esa referencia aunque tu ruta no conserve una compra en la fecha final.

Incluye clientes identificados con al menos una compra válida en ese periodo. Agrupa las líneas por cliente y factura cuando sea necesario para distinguir pedidos de productos; finalmente genera una sola fila por cliente. Calcula los días con fechas normalizadas a medianoche para que la hora no reste un día por truncamiento.

Campo de salida	Definición
CustomerID	Identificador de cliente conservado como clave
Recency	Días de calendario entre el 10 de diciembre de 2011 y la fecha de su última compra válida
Frequency	Número de facturas de compra válida distintas del cliente en todo el periodo
Monetary	Suma de LineAmount del cliente en todo el periodo, según la definición A o B documentada

Exporta clientes_rfm.csv con esas cuatro columnas, sin índice adicional. No apliques logaritmos, escalamiento ni agrupamientos. Si Monetary resulta cero o negativo, consérvalo para esta revisión y explica su origen; identifica esos casos antes del modelado posterior.

Control de validación RFM

Comprobación	Resultado y evidencia
Clientes incluidos y filas del archivo	[Completar]
CustomerID nulos y duplicados	[Completar]
Fecha de referencia y primera y última compra utilizadas	[Completar]
Recency mínimo y máximo y Frequency mínimo	[Completar]
Suma de Monetary frente a movimientos elegibles	[Completar]
Clientes con Monetary ≤ 0 y explicación	[Completar]

1. En la libreta, comprueba manualmente dos clientes con distinto número de pedidos: muestra sus facturas válidas, última fecha e importe según la ruta. ¿Cómo cambiaría Frequency si contaras líneas? ¿Cómo interpretas un cliente frecuente con Monetary reducido por abonos?

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

II Clasificación de recompra y límites temporales

Fija el corte en el 1 de julio de 2011 a las 00:00. El archivo original cubre por completo las ventanas requeridas. Comprueba que utilizas los dos años disponibles y que ningún filtro previo haya truncado las fechas necesarias.

Uso	Inicio incluido	Fin excluido
Historial de 180 días	2 de enero de 2011 a las 00:00	1 de julio de 2011 a las 00:00
Observación de recompra de 90 días	1 de julio de 2011 a las 00:00	29 de septiembre de 2011 a las 00:00

Selecciona inicio ≤ InvoiceDate < fin en ambas ventanas. Así, el historial incluye todo el 30 de junio y la etiqueta incluye todo el 28 de septiembre. Una compra del 1 de julio pertenece a la observación de recompra; una del 29 de septiembre queda fuera. Las ventanas no comparten transacciones.

Población y predictoras

1. Forma la población con los clientes identificados que tengan al menos una compra válida en la ventana histórica. Esta lista fija las filas de salida. Un cliente que solo aparece después del corte no entra en esa población.

2. Calcula las siguientes variables exclusivamente dentro de los 180 días históricos. En este ejercicio, TotalOrders y TotalSpent no acumulan todo el historial desde 2009.

Campo	Cálculo y uso
CustomerID	Clave del cliente; se conserva solo como identificador
RecencyDays	Días de calendario entre el corte y la última compra válida histórica, con fechas sin hora
TotalOrders	Facturas de compra válida distintas en los 180 días históricos
TotalSpent	Suma histórica de LineAmount según A o B, solo entre el 2 de enero incluido y el corte excluido

Asignación de Repurchase90Days

3. Identifica los CustomerID distintos con al menos una compra válida en la ventana posterior. Usa solo compras positivas sin C; un cliente con únicamente un abono en esa ventana no cumple la condición.

4. Conserva la tabla completa de clientes históricos y asigna 1 cuando su CustomerID pertenezca a la lista de compradores posteriores, y 0 en los demás casos. Puedes usar isin() sobre la clave o un left merge con una lista posterior sin duplicados. Si usas una unión, convierte únicamente la marca posterior faltante en 0; no rellenes de ese modo las variables históricas.

5. Revisa que la unión no elimine clientes ni multiplique filas. Una unión interna conservaría solo a quienes recompraron y perdería la clase 0. La ausencia de compra posterior significa 0 dentro de esta población y este horizonte; no implica falta de historial ni abandono definitivo.

Control de validación de la clasificación

Exporta clientes_clasificacion.csv, sin índice adicional, con CustomerID, RecencyDays, TotalOrders, TotalSpent y Repurchase90Days, en ese orden. Conserva ambas clases y sus proporciones originales.

Verificación obligatoria	Resultado y evidencia
Filas finales frente a clientes distintos de la población histórica	[Completar]
CustomerID nulos y duplicados	[Completar]
Valores únicos de Repurchase90Days y ausencia de etiquetas nulas	[Completar]
RecencyDays entre 1 y 180 y TotalOrders entero de al menos 1	[Completar]
Fechas mínima y máxima usadas en las predictoras	[Completar]
Fechas mínima y máxima usadas para observar recompra	[Completar]
Ausencia de movimientos posteriores al corte en TotalSpent	[Completar]
TotalSpent reproducible según la ruta y sin valores faltantes	[Completar]

Si TotalSpent es cero o negativo bajo B, revisa sus compras y abonos históricos y documenta el resultado. No lo conviertas en positivo ni uses devoluciones futuras para corregirlo.

Repurchase90Days	Significado	Clientes	Porcentaje
0	Sin compra válida en los 90 días posteriores	[Completar]	[Completar]
1	Al menos una compra válida en esos 90 días	[Completar]	[Completar]
Total	Población histórica completa	[Completar]	100 %

Calcula cada porcentaje sobre todos los clientes de la población histórica. La suma de las dos clases debe coincidir con las filas del archivo y sus porcentajes deben sumar 100 %, salvo redondeo de presentación.

2. Selecciona un cliente de cada clase y muestra en la libreta las compras que justifican su etiqueta. Para el cliente con 0, comprueba que sí tiene historial válido y que no tiene compras válidas en la ventana posterior. Si solo registra abonos posteriores, explica por qué su etiqueta sigue siendo 0.

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

3. Explica qué alteración produciría incluir una compra de agosto en TotalSpent o calcular RecencyDays con una compra posterior al corte. Comprueba también que las ventas de clientes nuevos posteriores no hayan creado filas adicionales.

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

4. A partir de la distribución obtenida, ¿qué proporción de la población volvió a comprar? Formula una lectura comercial limitada a esos 90 días y señala por qué la clase 0 no identifica por sí sola a clientes perdidos de manera definitiva.

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

Entrega y evaluación de los conjuntos analíticos

Completa este control con los nombres reales de tus archivos y la sección de la libreta que permite reproducirlos. Incorpora una vista de las primeras cinco filas de cada conjunto en la libreta; no es necesario copiar todo el dataset al reporte.

Conjunto	Filas y columnas	Clave y periodo	Sección de la libreta
clientes_rfm.csv	[Completar]	[Completar]	[Completar]
clientes_clasificacion.csv	[Completar]	[Completar]	[Completar]

5. ¿Por qué los dos conjuntos pueden incluir cantidades distintas de clientes aunque procedan del mismo archivo? Explica la diferencia entre el periodo completo de RFM y la población histórica de clasificación. Señala cómo afectó la falta de identificador al alcance del análisis.

Respuesta e interpretación: [Completa con evidencia de tu libreta.]

Entregables

1. Libreta .ipynb ejecutada con la construcción y las verificaciones de ambos conjuntos.
2. clientes_rfm.csv.
3. clientes_clasificacion.csv.
4. Este documento con los controles y las respuestas completos, como reporte breve de validación.

Límite de la actividad

La entrega termina con las tablas verificadas. La partición de entrenamiento y prueba, estratificación, transformaciones, algoritmos y métricas se realizarán después. No construyas todavía covariables temporales para regresión.

Referencias

Chen, D. (2012). Online Retail II [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5CG6D

Caso de Estudio North Quay Gifts. Material proporcionado. https://docs.google.com/document/d/1luKfmlQgW3RHrsZAIXC30ydZrni3wRQvnw8s3VlLRss/edit